
3 2 3

cs231n sumary


LECTURE 6


Activation Function

- Linear → non-linear why? Linear-multi-layer = single layer
- E.g $w_1(w_2 \dots (w_n x + b_n) \dots) = w_{n+1} x + b_{n+1}$



Sigmoid and tanh







$$\tanh(\mathbf{x}) = 2\sigma(2x) - 1$$


	Sigmoid	Tanh(scaled of sig)
장점	[0,1]로 squash(뭉갬)	[-1,1]로 squash
	Nice interpretation as a saturating firing rate of a neuron.	Zig-zag path가 적다
단점	 Exp() 비용이 비쌈 Saturation 이 weight 학습을 죽임(기울기 0인 지점) 	
	0-cente가 아님 → 비효율적인 gradient 탐색(zig-zag path)	

Sigmoid and tanh

Output is not zero-centered
 If all x>0








Zig-zag path

Efficient way

Hypothetical optimal w vector


ReLu




ReLU $f(x) = \max(0, x)$

- + region, no saturation(포화)
- 계산적 이점
- Sigmoid/tanh보다 빠른 수렴속도(6배)
- Sigmoid보다 생물학적으로 유사함 단점
- 0-중심이 아님 : 비효율적인 decent탐색
- - region , gradient died

Other ReLu





$$f(x) = \max(0.01x, x)$$

Leaky ReLU
$$f(x) = \max(0.01x,x) \quad f(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha \ (\exp(x) - 1) & \text{if } x \leq 0 \end{cases}$$


Exp ReLu


Max out Neuron

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

- ReLu, Leaky ReLU 의 일반화
- NO saturate, NO die
- 문제는 하나의 activation function에 두개의 변수(뉴런)

Data Processing





e.g. consider CIFAR-10 example with [32,32,3] images


- Subtract the mean image (e.g. AlexNet) (mean image = [32,32,3] array)
- Subtract per-channel mean (e.g. VGGNet) (mean along each channel = 3 numbers)


Weight Initialization


• W값을 초기화하는 것에 관심이 없었으나 performance에 꽤 영향을 주기 때문에 관심이 생김

10layer – 500 neuron tanh activation function

- W =0 으로 초기화하면 모든 w가 같은 값으로 updating → 적합하지않음
- W = 0.01*np.random.randn(D,H) 충분히 작은 랜덤 숫자 →
 단일 층에는 잘작동하나 층이 깊어지면 activation 을 0으로
 만들어버림 → 업데이팅이 안됨
- W = 1*np.random.randn(D,H) 큰 랜덤 숫자 → -1,1로 포화 되서 gradien가 0이 되서 업데이팅이 안됨.









Input 의 distribution이 normalization되면 좋을텐데..

Input whitening? (mean = 0, dev = 1) → 단점이 많다

공분산 계산,inverse계산, 가장 큰 문제 : 일부 parameter등의 희석(e.g bias)






1. compute the empirical mean and variance independently for each dimension.

2. Normalize

$$\widehat{x}^{(k)} = \frac{x^{(k)} - E[x^{(k)}]}{\sqrt{\text{Var}[x^{(k)}]}}$$



// scale and shift

Input: Values of x over a mini-batch: $\mathcal{B} = \{x_{1...m}\}$;

Parameters to be learned: γ , β

Output: $\{y_i = BN_{\gamma,\beta}(x_i)\}$


 $y_i \leftarrow \gamma \widehat{x}_i + \beta \equiv BN_{\gamma,\beta}(x_i)$

$$\mu_{\mathcal{B}} \leftarrow \frac{1}{m} \sum_{i=1}^{m} x_{i} \qquad // \text{ mini-batch mean}$$


$$\sigma_{\mathcal{B}}^{2} \leftarrow \frac{1}{m} \sum_{i=1}^{m} (x_{i} - \mu_{\mathcal{B}})^{2} \qquad // \text{ mini-batch variance}$$

$$\widehat{x}_{i} \leftarrow \frac{x_{i} - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^{2} + \epsilon}} \qquad // \text{ normalize}$$

- Gradient가 매우 잘 전달됨
- 학습 진도율이 높아짐
- W초기화에 의존하지 않아도됨
- Regularization 의 효과가 있어 drop out 을 쓸필요가 적어진다.




$$\gamma, \beta$$
 는 학습가능



Baby sitting Learning Process

- Training 모니터를 어떻게 할까
- Hyperparameter를 원하는 방향으로 조정
- 1) 데이터 전처리
- 2) 아키텍쳐 정하기
- Loss 값을 확인 regularization이 있을때 없을때를 비교.
 learning rate를 조정
- 기타 파라미터값들..
- Hyperparameter 설정에 힌트가 될수도있음

Baby sitting Learning Process




신경망 첫 층의 웨이트값(weight)를 시각화한 에. 좌측: 특징값(feature)에 잡음(noise)이 많을 때 나타날 수 있는 증상: 수렴하지 않은 망(network), 적절하지 않은 학습 속도(learning rate), 매우 낮은 정규화 페널티(regularization penalty). 우측: 부드럽고 깨끗하며 다양한 피쳐값들이 보이는 경우 훈련이 잘 진행되고 있다는 지표일 수 있다.


Hyperparameter Optimization

- 학습속도의 초기값(the initial learning rate)
- 학습속도 경감 계획, 이를테면 경감 상수 (learning rate decay schedule (such as the decay constant))
- L2나 드랍아웃 페널티의 정규화 강도 (regularization strength (L2 penalty, dropout strength))
 몇가지 TIP
- **초모수의 범위 (Hyperparameter ranges)**. 로그 스케일로 초모수를 찾아라
- 그리드 검색보다는 임의 검색 (Prefer random search to grid search)
- 가장 좋은 값이 경계에 있으면 조심하라 (Careful with best values on border) (범위오류일지도)
- 성긴 검색에서 촘촘한 검색으로 (Stage your search from coarse to fine).
- 베이지안 초모수 최적화 (Bayesian Hyperparameter Optimization)


Hyperparameter Optimization



빠른 수렴속도를 갖는게 좋다. Epoch(자료가 학습(SGD)에 사용된 수)



초기설정이 별 로였음



Gap 이 크면 overfitting 줄이는 게 좋다.

Thanks